

Auditoría de Calidad de Datos

NovaMarket: informe de hallazgos y plan de remediación

Dataset auditado: NovaMarket_datos_crudos.csv · 620 registros × 14 variables

Integrantes: María Andrea Torres · Ricardo Borja · Gabriel Murillo Velandia · Laura Marcela Gómez

Fecha: Agosto de 2026

1 Resumen ejecutivo

El dataset de ventas de NovaMarket presenta problemas de calidad **sistémicos** que lo hacen inadecuado para análisis directo sin una etapa previa de depuración. La auditoría, realizada sobre las seis dimensiones estándar de calidad de datos, identificó **18 problemas** distribuidos en las 14 variables del archivo.

620

registros auditados

18

problemas detectados

3

columnas con >50% de
inconsistencia

20.3%

pedidos con fecha futura

El hallazgo dominante es la **inconsistencia de escritura en las variables categóricas**: más de la mitad de los valores de *ciudad* (59.6%), *nivel_satisfaccion* (58.5%) y *categoria_producto* (51.8%) está escrito en una forma distinta a la canónica, con diferencias de mayúsculas, tildes o sinónimos que fragmentan una misma clase en varias. A esto se suma una **integridad temporal comprometida** (uno de cada cinco pedidos tiene fecha de compra posterior a la fecha actual) y **violaciones de validez numérica** (precios y unidades negativos, edades imposibles y valores atípicos extremos).

Conclusión. Los datos no deben usarse para segmentación, series temporales ni agregados de negocio en su estado actual. Se recomienda ejecutar el plan de remediación priorizado de la sección 5 antes de cualquier análisis, comenzando por la estandarización de las variables categóricas, que es la corrección de mayor retorno.

2 Alcance y metodología

La auditoría evalúa el dataset contra las seis dimensiones de calidad de datos, cuantificando cada problema con su número de registros afectados y su porcentaje sobre el total:


- **Completitud:** presencia de valores faltantes por columna.
- **Validez:** cumplimiento de formatos y reglas de dominio (patrones de identificador, formato de fecha y correo, rangos numéricos admisibles).

- **Consistencia:** representación uniforme de un mismo concepto, tomando como forma canónica la variante más frecuente de cada grupo.
- **Exactitud:** coherencia frente a una **fuentes de verdad externa:** el catálogo oficial de códigos postales de Colombia (Datos Abiertos / 4-72), contra el que se contrasta la correspondencia entre *codigo_postal* y *ciudad*.
- **Unicidad:** ausencia de duplicados en el identificador de pedido.
- **Oportunidad:** sentido temporal de las fechas (se marcan como inválidas las posteriores a la fecha actual).

3 Hallazgos por dimensión

3.1 Consistencia: el problema de mayor alcance

Es la dimensión más afectada y la de mayor impacto sobre el negocio. En las tres variables categóricas clave, más de la mitad de los registros no coincide con la forma canónica: la columna *ciudad* aparece en 19 variantes distintas para un puñado de municipios reales (p. ej. "Bogotá", "bogota", "bogota d.c."), y lo mismo ocurre con los niveles de satisfacción escritos en diferentes casings y con categorías de producto sinónimas ("juguetes" frente a "jugueteria"). Cualquier agrupación, conteo por ciudad o distribución de satisfacción queda corrompida porque una misma clase se cuenta como varias.



Porcentaje de registros fuera de la forma canónica en las tres variables categóricas principales.

3.2 Oportunidad: integridad temporal


El 20.32% de los registros (126 pedidos) tiene una *fecha_compra* posterior a la fecha actual, lo que invalida cualquier análisis de serie temporal sobre el eje de compras. En menor medida, un 3.39% de los registros presenta una *fecha_actualizacion_stock* también futura. El patrón sugiere errores de captura o de año mal digitado más que ruido aleatorio.

3.3 Validez: formatos y rangos

Se detectaron violaciones de dominio en las variables numéricas que participan en cálculos de negocio: *edad_cliente* fuera del rango humano admisible (5.16%, con valores negativos y hasta 200), *unidades* ≤ 0 (5.00%) y *precio* ≤ 0 (3.06%), además de valores atípicos extremos, con precios por encima de 100 millones (0.97%) y cantidades de 9999 unidades (2.42%), que probablemente son errores de digitación o valores centinela. En formatos, un 8.23% de los correos no cumple una estructura válida (por ejemplo, sin el carácter "@") y un 3.55% de las fechas de compra no es reconocible como fecha.

3.4 Completitud: valores faltantes

La ausencia de datos se concentra en cuatro columnas. El *correo* es la de mayor volumen (16.77%), pero su impacto operativo es bajo porque no entra en cálculos ni modelos. Le siguen *nivel_satisfaccion* (7.42%), *ciudad* (5.00%) y *precio* (3.39%); esta última, aunque baja en proporción, es crítica por participar en los agregados estadísticos y conviene imputarla antes que eliminar registros.



Porcentaje de valores faltantes por columna (solo columnas con ausencias).

3.5 Exactitud: verificación contra fuente oficial

Cruzando el código postal de cada registro contra el catálogo oficial para obtener el municipio que representa, se encontró que **45 de 620 registros (7.26%)** declaran una *ciudad* que no corresponde a su *codigo_postal*. Es el único hallazgo verificado contra una fuente de verdad externa e independiente, lo que le da un peso particular sobre la fiabilidad de la geolocalización.

3.6 Unicidad: duplicados de pedido


El identificador de pedido, que debería ser único por registro, presenta **20 duplicados (3.23%)**. Los duplicados inflan artificialmente los conteos de pedidos y deben resolverse conservando el registro más completo de cada grupo o investigando su origen como error de carga.

4 Catálogo priorizado de problemas

Los 18 problemas detectados, ordenados por severidad y con su alcance cuantificado. La severidad combina la **magnitud** (proporción de registros afectados) con la **críticidad funcional** (qué análisis se rompe), no solo el volumen.

#	Problema	Dimensión	Reg.	%	Severidad
1	Inconsistencia de escritura en ciudad	Consistencia	351	59.59%	Alto
2	Inconsistencia en nivel_satisfaccion	Consistencia	336	58.54%	Alto
3	Inconsistencia en categoria_producto	Consistencia	321	51.77%	Alto
4	Fechas futuras en fecha_compra	Oportunidad	126	20.32%	Alto
5	Código postal no corresponde a la ciudad	Exactitud	45	7.26%	Medio

#	Problema	Dimensión	Reg.	%	Severidad
6	Valores faltantes en correo	Compleitud	104	16.77%	Bajo
7	Correos con formato inválido (sin @)	Validez	51	8.23%	Medio
8	Valores faltantes en nivel_satisfaccion	Compleitud	46	7.42%	Medio
9	edad_cliente fuera de rango (<0 o >120)	Validez	32	5.16%	Medio
10	unidades ≤ 0 (negativas o cero)	Validez	31	5.00%	Medio
11	Valores faltantes en ciudad	Compleitud	31	5.00%	Medio
12	Formato de fecha no reconocible	Validez	22	3.55%	Medio
13	fecha_actualizacion_stock futura	Oportunidad	21	3.39%	Bajo
14	Valores faltantes en precio	Compleitud	21	3.39%	Medio
15	id_pedido duplicados	Unicidad	20	3.23%	Medio
16	precio ≤ 0 (negativo)	Validez	19	3.06%	Medio
17	unidades atípicas extremas (p. ej. 9999)	Validez	15	2.42%	Medio
18	precio atípico extremo (>100M)	Validez	6	0.97%	Medio



Problemas de mayor alcance por porcentaje de registros afectados.



Alto (4) Medio (12) Bajo (2)

Distribución de los 18 problemas por severidad.

5 Priorización

La secuencia de remediación se ordena por impacto sobre los análisis de negocio, combinando magnitud y criticidad funcional. Por eso el *correo faltante*, pese a ser el nulo más numeroso, queda en prioridad baja, mientras la consistencia categórica encabeza la lista.

Prioridad alta

- **Consistencia de ciudad, nivel_satisfaccion y categoria_producto** (59.6%, 58.5% y 51.8%). Es el problema más extendido y contamina directamente los indicadores que consume el negocio: conteos por ciudad, distribución de satisfacción y ventas por categoría.
- **Fechas futuras en fecha_compra** (20.32%). Invalidan el eje temporal completo de cualquier serie de compras.
- **Código postal incoherente con la ciudad**. Compromete la geolocalización y es el único hallazgo verificado contra fuente oficial externa.

Prioridad media

- **Validez numérica** (edad fuera de rango, unidades y precio ≤ 0 , atípicos extremos). Proporciones moderadas, pero afectan variables que entran en sumas y promedios como ingresos y ticket promedio.
- **Correos inválidos** (8.23%) y **duplicados de id_pedido** (3.23%). Afectan contactabilidad y conteos de pedidos.
- **Faltantes en nivel_satisfaccion, ciudad y precio**. Ausencias moderadas que requieren decisión de imputación o exclusión.

Prioridad baja

- **Faltantes en correo** (16.77%). El mayor volumen de nulos, pero sin efecto sobre cálculos ni modelos.
- **fecha_actualizacion_stock futura** (3.39%). Baja proporción y menor criticidad que la fecha de compra.

6 Plan de remediación

Tratamiento sugerido por grupo de problemas, para aplicar en la siguiente etapa de preprocesamiento:

Consistencia (ciudad, categoria_producto, nivel_satisfaccion). Estandarizar a una forma canónica mediante normalización (minúsculas, sin tildes, recorte de espacios) más un diccionario de equivalencias para los casos semánticos ("B/quilla" → Barranquilla, "juguetes" → Juguetería). Definir un catálogo cerrado por columna y mapear todo valor a él. Es la corrección de mayor retorno.

Oportunidad (fechas futuras). Revisar el origen de las fechas posteriores a hoy, que son probablemente errores de captura o de año mal digitado. Decidir entre corregir, si el patrón es identificable, o marcar como inválidas y excluir de los análisis temporales.

Exactitud (código postal ↔ ciudad). Resolver primero el formato del código postal (dígitos faltantes) y, para los registros incoherentes, priorizar la fuente más confiable, código o ciudad, apoyándose en la tabla oficial para reconstruir el valor correcto.

Validez numérica. Tratar precio ≤ 0 y unidades ≤ 0 como faltantes e imputar (mediana para precio) o excluir según la regla de negocio. Investigar los atípicos extremos (precio $> 100M$, unidades = 9999) como posibles errores de digitación o centinelas. Imputar o marcar como desconocida la edad fuera de rango.

Validez de correo. Corregir los correos sin "@" cuando el patrón lo permita (p. ej. insertar el "@" faltante en "c0276gmail.com"); si no, marcarlos como inválidos.

Unicidad (id_pedido). Deduplicar conservando el registro más completo de cada grupo, o investigar si los duplicados corresponden a un error de carga.

Complejidad. Imputar donde la variable participa en cálculos (precio → mediana; nivel_satisfaccion → categoría "sin dato"); el correo faltante puede dejarse vacío o marcarse como desconocido dado su bajo impacto operativo.