

Auditoría de Calidad de Datos

NovaMarket: informe de hallazgos y plan de remediación

Dataset auditado: NovaMarket_datos_crudos.csv · 640.000 registros × 20 variables
Integrantes: María Andrea Torres · Ricardo Borja · Gabriel Murillo Velandia · Laura Marcela Gómez
Fecha de corte de la auditoría: 4 de agosto de 2026
Documentos que acompañan este informe: S3_Grupo05_AuditoriaCalidad.ipynb y S3_Grupo05_CatalogoProblemas.xlsx

1. Resumen ejecutivo

El dataset de ventas de NovaMarket presenta problemas de calidad sistémicos que lo hacen inadecuado para análisis directo sin una etapa previa de depuración. La auditoría se realizó sobre las seis dimensiones estándar de calidad de datos e identificó **38 problemas** distribuidos en las 20 variables del archivo, cada uno cuantificado con su número de registros afectados y su porcentaje sobre el total.

640.000 registros auditados en 20 variables	38 problemas detectados en 6 dimensiones	10 de severidad alta	49,20% el mayor problema: escritura de ciudad	7 hallazgos que no se corrigen con limpieza
--	---	--------------------------------	--	--

El hallazgo dominante sigue siendo la inconsistencia de escritura en las variables categóricas. Casi la mitad de los valores de `ciudad_tienda` (49,20%) y de `categoria_producto` (47,61%) está escrito en una forma distinta a la canónica, con diferencias de mayúsculas, tildes, espacios sobrantes, abreviaturas de tres letras y nombres largos que fragmentan una misma clase en varias. Es también el problema de corrección más barata, puesto que se resuelve con un diccionario de equivalencias.

El hallazgo más grave, sin embargo, es de otra naturaleza. La edad de un mismo cliente varía mucho más de lo que permite la ventana temporal del archivo: los pedidos cubren tres años, de modo que nadie puede envejecer más de tres, y sin embargo el rango mediano dentro de un mismo `id_cliente` es de cuarenta años. A eso se suma que la condición de fuga alterna de forma repetida, que el correo se deriva del pedido y no de la persona, que ni el precio ni el peso guardan relación con el artículo, y que la fecha de actualización de stock se comporta como un dato de la transacción y no del inventario. Estos siete hallazgos no se resuelven limpiando el archivo, ya que el valor correcto sencillamente no está en él, por lo que hay que devolverlos al área que lo genera.

Conclusión. Los datos no deben usarse para segmentación, series temporales, análisis por cliente ni agregados de negocio en su estado actual. Se recomienda ejecutar el plan de remediación priorizado de la sección 6 antes de cualquier análisis, comenzando por la estandarización de las variables categóricas, que es la corrección de mayor retorno, y escalando en paralelo al área responsable los siete hallazgos que la limpieza no puede resolver.

2. Alcance y metodología

La auditoría evalúa el dataset contra las seis dimensiones de calidad de datos. Cada problema se cuantifica con su número de registros afectados y su porcentaje sobre los 640.000 del archivo, de modo que todas las cifras del informe

son directamente comparables entre sí.


- **Compleitud:** presencia de valores faltantes por columna. La medición no se limita a los nulos que reporta `isnull()`, ya que un dato ausente puede estar escrito como celda vacía, como cadena de solo espacios o como un centinela textual del tipo `-`, `sin dato` o `00/00/0000`. Para poder distinguirlos el archivo se lee dos veces, una normal y otra en texto crudo con `keep_default_na=False`.
- **Validez:** cumplimiento de formatos y reglas de dominio: patrones de identificador, formato de fecha y de correo, y rangos numéricos admisibles.
- **Consistencia:** representación uniforme de un mismo concepto, tomando como forma canónica la variante más frecuente de cada grupo.
- **Exactitud:** coherencia frente a una fuente de verdad externa y frente al resto del registro. La fuente externa es la **codificación DIVIPOLA del DANE**, contra la que se contrasta la correspondencia entre `codigo_postal` y `ciudad_tienda`.
- **Unicidad:** ausencia de duplicados, verificada bajo dos criterios distintos: identificador de pedido repetido y fila idéntica en las 20 columnas.
- **Oportunidad:** vigencia y sentido temporal de las fechas, incluida la antigüedad del último recuento de inventario frente a un umbral de negocio de 180 días.

Sobre el tamaño del archivo. El enunciado del caso menciona 620.000 registros y el archivo entregado tiene 640.000. La diferencia se explica de forma exacta: son las 20.000 filas duplicadas que documenta la sección 3.5. Tras deduplicar, el archivo queda en 620.000 registros.

3. Hallazgos por dimensión

3.1 Consistencia: el problema de mayor alcance

Es la dimensión más extendida y la de mayor impacto sobre el negocio. Cinco columnas categóricas presentan el mismo concepto escrito de varias formas, y en las dos principales casi la mitad de los registros no coincide con la forma canónica. `ciudad_tienda` es el caso más severo, con **88 variantes crudas para 12 ciudades reales**, y acumula tres tipos de variante a la vez: tipográficas (`Bogotá`, `bogota`, `BOGOTÁ`, `Bogotá` con espacio inicial), contracciones y nombres largos (`B/quilla`, `Sta. Marta`, `Santiago de Cali`) y códigos de tres letras (`BOG`, `MDE`, `CTG`). Solo el grupo de Bogotá reúne 50.810 registros repartidos en once formas de escritura distintas.




Porcentaje de registros que no usan la forma canónica de su columna. `nivel_lealtad` se incluye como control: llega limpia, con 4 variantes para 4 categorías y ningún registro a ajustar, lo cual confirma que el método no marca inconsistencia donde no la hay.

3.2 Completitud: valores faltantes y falsos completos

Siete de las 20 columnas presentan vacíos y trece están completas. `correo_cliente` es la de mayor volumen (16,46%), pero su impacto operativo es bajo porque no entra en cálculos ni modelos. Las críticas son `precio_unitario` y `monto_compra`, que aunque bajas en proporción participan en todos los agregados de venta, y `ciudad_tienda`, que rompe la segmentación geográfica pero es el faltante más barato de corregir, ya que `codigo_postal` está completo al 100% y sus cinco primeros dígitos identifican el municipio de forma determinista.

El resultado que justifica haber cambiado la forma de medir es `fecha_pedido`. Con el conteo tradicional de nulos figura como completa al 100%, puesto que sus 640.000 celdas tienen contenido. Leyendo el archivo en texto crudo se ve que 5.698 de ellas dicen `00/00/0000`, que es un marcador de fecha ausente y no una fecha. Se verificaron 41 centinelas distintos sobre las 20 columnas y este fue el único que apareció, junto con la confirmación de que ninguna celda contiene solo espacios.

Vacío efectivo por columna (celda vacía, solo espacios o centinela textual)



Vacío efectivo por columna. Solo las siete con ausencias aparecen en el gráfico.

3.3 Validez: formatos y rangos

Es la dimensión con más problemas distintos (once), aunque cada uno de proporción moderada. Las violaciones de dominio se concentran en las variables numéricas que participan en cálculos de negocio: `edad_cliente` fuera del rango humano admisible (4,35%, con valores desde -5 hasta 200 años), `unidades_vendidas` ≤ 0 (4,36%) y `precio_unitario` negativo (3,07%, hasta -\$888.100). A ello se suman valores atípicos extremos: precios de hasta \$999.000.000 y cantidades de 5.000 y 9.999 unidades por pedido.

En formatos, un 8,05% de los correos no cumple una estructura válida, con la forma `cliente593809.hotmail.com` en la que el signo @ fue reemplazado por un punto, y un 3,54% de las fechas de pedido no es reconocible como fecha. Estas últimas son cuatro valores concretos que conviene separar, puesto que exigen tratamientos distintos: `30/02/2025` (5.675), `31/04/2025` (5.688) y `2026-13-05` (5.626) son errores de digitación de una fecha que sí existe en el origen, mientras que `00/00/0000` (5.698) es un dato ausente ya contabilizado en completitud.

Lo que no falla también es un resultado. Los patrones de `id_pedido` e `id_cliente` se cumplen en el 100% de los registros y ninguna columna categórica toma valores fuera de su lista admisible. Eso no significa que el filtro esté mal escrito: significa que el problema de esas columnas es de consistencia de escritura y no de validez, y sirve como control de que los conteos que sí se reportan son creíbles.

3.4 Exactitud: verificación contra fuente oficial y coherencia interna

El `codigo_postal` de esta versión tiene siete dígitos y su estructura es jerárquica: los cinco primeros son el código de municipio de la codificación DIVIPOLA del DANE y los dos últimos identifican la sede. Verificando los 493 códigos distintos del archivo, sus cinco primeros dígitos se reducen a exactamente doce municipios, los doce de las tiendas de NovaMarket. Cruzando ese código contra la ciudad declarada se encontró que **42.405 registros (6,63% de la base y 6,95% de los evaluables)** declaran una ciudad que no corresponde a su código postal, repartidos en 132 combinaciones distintas con un promedio de 321 registros cada una, es decir sin concentrarse en ninguna sede en particular. Los 29.928 registros sin ciudad se excluyeron del cálculo por ser un problema de completitud ya contabilizado.

Además del contraste externo se auditaron ocho reglas de coherencia interna entre columnas del mismo registro. Tres se cumplen y cinco fallan. Entre las que se cumplen está la identidad `monto_compra = precio_unitario × unidades_vendidas`, verificada en el 100% de los 618.360 registros evaluables con diferencia máxima de cero, lo cual permite afirmar que los 45.182 montos ≤ 0 son el arrastre aritmético exacto de los precios y las unidades negativas y no un error propio de esa columna.

3.5 Unicidad: dos criterios que hay que separar


La verificación se hizo bajo dos criterios distintos, porque de su cruce depende cuál es la corrección correcta: un identificador repetido con filas distintas obligaría a reasignar códigos sin poder borrar nada, mientras que un identificador repetido con filas idénticas es una carga duplicada que se resuelve borrando. Los dos criterios coinciden exactamente: las 40.000 filas implicadas en un `id_pedido` repetido son las mismas 40.000 que forman pares idénticos en las 20 columnas, y cada identificador afectado aparece exactamente dos veces. No hay ni una sola colisión real de clave.

El diagnóstico es entonces carga duplicada del archivo, y la corrección es una sola instrucción, `drop_duplicates()`, que elimina las 20.000 copias sobrantes sin riesgo de perder información. El resultado son 620.000 registros, que es exactamente el tamaño que menciona el enunciado del caso.

3.6 Oportunidad: vigencia del inventario

Se adoptó como regla de negocio que un recuento de inventario con más de **180 días** de antigüedad ya no describe la disponibilidad actual, de modo que cualquier decisión de reposición basada en él sería a ciegas. El umbral se dejó como parámetro modificable en el código, puesto que depende de la rotación real del inventario y debería validarse con el área de logística. Bajo ese criterio, 66.069 registros (10,32%) tienen el stock desactualizado, 422.000 (65,94%) tienen las dos fechas del registro separadas por más de medio año y 102.835 (16,07%) traen una fecha de stock anterior a la del pedido.

Al medir la antigüedad apareció además un patrón que no corresponde a la operación continua de un inventario: los umbrales de 180, 365 y 540 días devuelven exactamente la misma cifra, porque **no existe ni un solo registro fechado en 2025**. Hay que consultar con el área responsable si en ese año hubo un cambio de sistema, una migración o una carga parcial, ya que eso explicaría el vacío y determinaría si los datos de ese periodo son recuperables.



4. Hallazgos que no se corrigen con limpieza

Siete de los 38 problemas merecen tratarse aparte, porque no son valores puntuales equivocados sino columnas que no se pueden validar contra la entidad que su nombre dice describir. En estos casos el alcance no se reporta como «registros con error» sino como el número de registros cuya verificación **queda sin resolver**: pasan las reglas de dominio, pero no existe ninguna referencia contra la cual contrastarlos.

- **La edad no es coherente con la ventana temporal del archivo.** Los pedidos cubren tres años, de modo que un cliente puede envejecer como máximo tres años entre su primer y su último pedido. El rango mediano de edad dentro de un mismo `id_cliente` es de **cuarenta años**, y el 97,9% de los clientes con dos o más pedidos supera el tope de tres. Alcance: 622.458 registros (97,26%). Ningún método de imputación puede reconstruir el valor verdadero, puesto que no hay forma de saber cuál de las edades de un cliente es la real.
- **La condición de fuga alterna de forma repetida.** 45.298 clientes entran y salen de ella dos o más veces, con un máximo de ocho alternancias, sobre una mediana de cuatro pedidos por cliente. Un cliente que abandona y regresa tantas veces no describe un estado de abandono. Alcance: 259.564 registros (40,56%).
- **El correo identifica al pedido y no a la persona.** Coincide con el `id_pedido` menos 100.000 en el 100% de los 534.688 registros con correo, y nunca con el `id_cliente`. La columna no sirve como dato de contacto mientras no se corrija en el origen.
- **El precio no se puede validar contra el artículo.** El producto explica una fracción despreciable de la varianza del precio ($\eta^2 = 0,000026$) y ninguno de los 120 grupos (producto, cantidad) tiene un precio único. Alcance: 592.567 registros (92,59%). Antes de concluir hay que descartar explicaciones legítimas con el área comercial: que el campo recoja el precio pagado tras descuentos en lugar del de lista, que los nombres agrupen referencias distintas o que el precio se capture de forma manual.
- **El peso no se puede validar contra el producto ni contra la cantidad.** $\eta^2 = 0,000046$ frente al producto y correlación de $-0,0009$ frente a las unidades vendidas: una bicicleta estática pesa en promedio lo mismo que una bufanda de lana, y un pedido de cinco unidades pesa lo mismo que uno de una sola. Este es el hallazgo más concluyente del bloque, ya que no depende de conocer el catálogo ni los precios de mercado sino de una relación física que el dato incumple. Alcance: 607.955 registros (94,99%).
- **La fecha de stock se comporta como dato del pedido.** Si describiera el inventario, todos los pedidos del mismo artículo en la misma sede entre dos reposiciones compartirían la misma fecha. El resultado es de 0,89 fechas distintas por pedido, y solo 37 de 7.406 grupos comparten una única fecha. Alcance: 639.005 registros (99,84%).
- **Falta el año 2025 completo** en la fecha de actualización de stock, según se documentó en la sección 3.6.

Un hallazgo candidato que se descartó a propósito. `nivel_lealtad` también toma varios valores dentro de un mismo cliente, y en una proporción alta: el 87,1%. Aun así **no se reporta como problema de calidad**, puesto que el nivel de lealtad es un segmento comercial que sube y baja con el comportamiento de compra por diseño, así que un mismo cliente puede pasar de Bronce a Plata o al revés sin que el dato esté mal. A diferencia de la edad, no existe un tope que permita separar el cambio válido del inválido, de modo que la medición no distingue un error de una promoción de segmento. Se deja constancia porque descartar un falso hallazgo también es resultado de la auditoría, y reportarlo habría inflado el diagnóstico con algo que no se sostiene.

Por qué una misma columna aparece varias veces en el catálogo. Puede parecer una contradicción decir que el precio no se puede validar y al mismo tiempo reportar errores concretos de precio. No lo es, ya que son dos comprobaciones distintas. Las **reglas de dominio** son absolutas y no necesitan referencia: un precio de venta no puede ser negativo y ningún artículo de este surtido cuesta más de diez millones de pesos. La **validación contra referencia** es relativa y sí la necesita: para decir si \$305.600 es el precio correcto de un *Rompecabezas 1000 piezas* hace falta una referencia por artículo, y esa referencia no existe en el archivo. El alcance que se reporta arriba es el complemento exacto de las reglas de dominio, por lo que las dos cifras suman el total y no se pisan entre sí:

Columna	Descartados por reglas de dominio	Sin verificar	Total
precio_unitario	21.640 sin dato + 19.629 negativos + 6.164 por encima de 10 millones = 47.433	592.567	640.000
peso_pedido_kg	32.045 por encima de 100 kg	607.955	640.000
fecha_actualizacion_stock	995 verificables: 74 en los 37 grupos con fecha única y 921 en grupos de un solo pedido	639.005	640.000

La lectura práctica es que los 47.433 registros de precio que sí se detectan son la parte pequeña del problema. El resto, el 92,59% de la columna, no se puede dar por bueno ni por malo, y esa incertidumbre es en sí misma el hallazgo que hay que reportar.

Cómo se descartó la explicación más obvia. Antes de afirmar que el precio no depende del artículo había que verificar que un mismo artículo no estuviera escrito de varias formas, lo cual mezclaría cosas distintas al agrupar. Los 24 nombres de producto se vectorizaron con TF-IDF de n-gramas de caracteres y se buscó el vecino más cercano de cada uno por distancia coseno: la distancia mínima es 0,695, muy por encima del umbral de 0,20 a partir del cual dos nombres serían variantes del mismo artículo. El catálogo de productos está limpio y la hipótesis queda descartada.

5. Catálogo priorizado de problemas

Los 38 problemas detectados, ordenados por severidad y con su alcance cuantificado. La severidad combina la magnitud (proporción de registros afectados) con la criticidad funcional (qué análisis se rompe), no solo el volumen. Por eso un problema que toca el 3% de los registros puede ser Alto y uno que toca el 16% puede ser Bajo. Este catálogo es el mismo contenido, fila por fila, del archivo `S3_Grupo05_CatalogoProblemas.xlsx`, donde cada problema aparece con su descripción completa. **Toda cifra que aparece aquí se calcula en una celda de código del notebook**, ninguna se escribió a mano.


#	Problema	Columna afectada	Dimensión	Reg.	%	Severidad
1	La edad varía dentro de un mismo cliente mucho más de lo que permite la ventana temporal del archivo.	edad_cliente, id_cliente	Exactitud	622.458	97,26%	Alta
2	No es posible validar el precio contra una referencia por artículo: el producto explica una fracción despreciable de la varianza del precio (eta cuadrado = 0,000026) y ninguno de los 120 grupos (producto, canti.	precio_unitario, producto	Exactitud	592.567	92,59%	Alta
3	El correo coincide con el id_pedido menos 100.000 en el 100% de los registros y nunca con el id_cliente, por lo que está asociado a la transacción y no a la persona.	correo_cliente	Exactitud	534.688	83,55%	Alta
4	88 variantes de escritura para 12 ciudades reales: mayúsculas, tildes, espacios sobrantes, contracciones (B/quilla, Sta.	ciudad_tienda	Consistencia	314.864	49,20%	Alta
5	32 variantes de escritura para 6 categorías reales, incluido el par sinónimo Juguetería/juguetes, que la normalización tipográfica no resuelve por sí sola.	categoria_producto	Consistencia	304.697	47,61%	Alta
6	La condición de fuga alterna de forma repetida dentro del mismo cliente: 45.298 clientes entran y salen de ella dos o más veces, con un máximo de 8 alternancias, sobre una mediana de 4 pedidos por cliente.	fuga_cliente, id_cliente	Exactitud	259.564	40,56%	Alta
7	20 variantes de escritura para 4 canales (Web, App, Tienda, Marketplace) por diferencias de mayúsculas y espacios sobrantes.	canal_compra	Consistencia	154.781	24,18%	Alta
8	20 variantes de escritura para 4 medios de pago (Efectivo, Tarjeta, PayPal, Transferencia), con el mismo patrón de mayúsculas y espacios que canal_compra.	metodo_pago	Consistencia	129.372	20,21%	Alta
9	15 variantes de escritura para 3 niveles (Alto, Medio, Bajo). Fragmenta cualquier agregado de satisfacción en varias clases que en realidad son la misma.	nivel_satisfaccion	Consistencia	95.706	14,95%	Alta

#	Problema	Columna afectada	Dimensión	Reg.	%	Severidad
10	16.485 pedidos con fecha posterior a la fecha de corte de la auditoría (04/08/2026), hasta 2027. Invalida el eje temporal de cualquier serie de compras.	fecha_pedido	Oportunidad	16.485	2,58%	Alta
11	La fecha de stock cambia en casi cada pedido: 0,89 fechas distintas por pedido dentro de cada pareja (sede, producto) y solo 37 de 7.406 grupos comparten una única fecha.	fecha_actualizacion_stock	Oportunidad	639.005	99,84%	Media
12	No es posible validar el peso contra el artículo ni contra la cantidad: eta cuadrado = 0,000046 frente al producto y correlación de -0,0009 frente a las unidades vendidas.	peso_pedido_kg	Exactitud	607.955	94,99%	Media
13	Pedido y actualización de stock separados por más de 180 días. Impide medir latencia de inventario, rotación y quiebre de stock.	fecha_pedido, fecha_actualizacion_stock	Oportunidad	422.000	65,94%	Media
14	Fecha de actualización de stock anterior a la fecha del pedido.	fecha_actualizacion_stock, fecha_pedido	Oportunidad	102.835	16,07%	Media
15	Pedidos que se apoyan en un recuento de stock hecho más de 180 días antes de la compra.	fecha_pedido, fecha_actualizacion_stock	Oportunidad	75.206	11,75%	Media
16	Stock desactualizado: más de 180 días desde el último recuento, umbral adoptado porque pasado ese plazo el dato ya no describe la disponibilidad actual y la decisión de reposición sería a ciegas.	fecha_actualizacion_stock	Oportunidad	66.069	10,32%	Media
17	No existe ningún registro fechado en 2025, pese a que sí hay 32.983 en 2023, 33.086 en 2024, 552.209 en 2026 y 21.722 en 2027. Por eso los umbrales de 180, 365 y 540 días devuelven la misma cifra.	fecha_actualizacion_stock	Oportunidad	66.069	10,32%	Media
18	Correos sin arroba, con la forma cliente593809@hotmail.com: el signo @ fue reemplazado por un punto. El perfilado por firma de patrón lo confirma de forma independiente.	correo_cliente	Validez	51.532	8,05%	Media
19	Registros sin nivel de satisfacción. Se pierde la observación en todo cruce de satisfacción y la ausencia puede no ser aleatoria.	nivel_satisfaccion	Complejidad	46.469	7,26%	Media
20	Monto de compra menor o igual a cero. Es el arrastre aritmético exacto de los precios y las unidades negativas, no un error propio de la columna: corregir el origen corrige el derivado.	monto_compra	Validez	45.182	7,06%	Media
21	El municipio DANE contenido en los 5 primeros dígitos del código postal no corresponde a la ciudad declarada. Verificado contra la codificación DIVIPOLA oficial.	ciudad_tienda, codigo_postal	Exactitud	42.405	6,63%	Media
22	Peso superior a 100 kg, hasta 1.399,9 kg, sobre una mediana de 11,7 kg, en un catálogo de bienes de consumo de tamaño medio.	peso_pedido_kg	Validez	32.045	5,01%	Media

#	Problema	Columna afectada	Dimensión	Reg.	%	Severidad
23	Registros sin ciudad de tienda. Rompe la segmentación geográfica, aunque son imputables de forma determinista desde codigo_postal, que está completo al 100%.	ciudad_tienda	Compleitud	29.928	4,68%	Media
24	Unidades vendidas menores o iguales a cero: 18.550 negativas, hasta -3 unidades por pedido, y 9.327 pedidos registrados con cero unidades.	unidades_vendidas	Validez	27.877	4,36%	Media
25	Edad fuera del rango 0 a 120 años: valores negativos hasta -5 y hasta 200 años.	edad_cliente	Validez	27.829	4,35%	Media
26	Fechas no convertibles a una fecha real. Son cuatro valores: 30/02/2025 (5.675), 31/04/2025 (5.688), 2026-13-05 (5.626) y 00/00/0000 (5.698).	fecha_pedido	Validez	22.687	3,54%	Media
27	Registros sin precio unitario. Entra en cálculos monetarios, por lo que imputarlo con la media distorsiona los agregados de venta.	precio_unitario	Compleitud	21.640	3,38%	Media
28	Registros sin monto de compra. Son exactamente las mismas filas que las de precio_unitario, porque el monto se deriva de él.	monto_compra	Compleitud	21.640	3,38%	Media
29	20.000 pedidos duplicados: el id_pedido se repite y además la fila es idéntica en las 20 columnas y cada identificador afectado aparece exactamente dos veces.	todas las columnas	Unicidad	20.000	3,12%	Media
30	Precio unitario negativo, hasta -\$888.100. Afecta directamente el cálculo de ingresos y arrastra el error a monto_compra.	precio_unitario	Validez	19.629	3,07%	Media
31	Unidades atípicas fuera de toda escala minorista, concentradas en solo dos valores: 5.000 y 9.999. Apunta a marcadores del sistema de origen antes que a errores de digitación.	unidades_vendidas	Validez	18.526	2,89%	Media
32	Monto de compra por encima de 1.000 millones de pesos en valor absoluto.	monto_compra	Validez	16.158	2,52%	Media
33	Precio unitario superior a \$10.000.000, con un máximo de \$999.000.000 idéntico en los 24 productos. Un tope repetido de esa forma apunta a un marcador del sistema de origen.	precio_unitario	Validez	6.164	0,96%	Media
34	Registros sin fecha de pedido, escritos como el texto 00/00/0000.	fecha_pedido	Compleitud	5.698	0,89%	Media
35	Precio unitario superior a 100 millones de pesos.	precio_unitario	Validez	3.050	0,48%	Media
36	Registros sin correo electrónico. Es el faltante de mayor volumen, pero no entra en promedios, sumas ni modelos, de modo que puede dejarse vacío o marcarse como desconocido.	correo_cliente	Compleitud	105.312	16,46%	Baja
37	Registros sin comentario. Es un texto libre opcional y su ausencia es informativa en sí	comentario_cliente	Compleitud	90.806	14,19%	Baja


#	Problema	Columna afectada	Dimensión	Reg.	%	Severidad
	misma, por lo que no debería imputarse.					
38	Fecha de actualización de stock posterior a la fecha de corte de la auditoría.	fecha_actualizacion_stock	Oportunidad	21.722	3,39%	Baja

Los problemas del catálogo no son mutuamente excluyentes y sus conteos no deben sumarse. Solapamientos conocidos: los montos ≤ 0 son el arrastre aritmético de los precios y las unidades negativos; los faltantes de `monto_compra` coinciden exactamente con los de `precio_unitario`; los 5.698 `00/00/0000` se cuentan en completitud y también dentro de los 22.687 formatos de fecha no reconocibles; y los faltantes de `ciudad_tienda` se excluyeron del cruce de exactitud para no contarlos dos veces.



Los problemas de mayor alcance del catálogo, medidos sobre los 640.000 registros.

Los 38 problemas por severidad



Distribución de los 37 problemas por severidad.

6. Priorización y plan de remediación

La secuencia se ordena por recuperación de datos por esfuerzo invertido, combinando magnitud y criticidad funcional. Por eso el correo faltante, pese a ser el nulo más numeroso, queda en prioridad baja, mientras la consistencia categórica encabeza la lista.

Prioridad alta

- **Estandarizar las cinco columnas categóricas.** Normalización tipográfica (minúsculas, sin tildes, recorte de espacios) más un diccionario de equivalencias para los casos semánticos (**B/quilla** → Barranquilla, **BOG** → Bogotá, **juguetes** → Juguetería), definiendo un catálogo cerrado por columna. Es la corrección de mayor retorno: recupera casi la mitad de la base con una sola pieza de código.
- **Escalar al área de origen los siete hallazgos de la sección 4.** No requieren desarrollo sino una decisión de negocio, y hasta que no se resuelvan bloquean todo análisis por cliente, todo cálculo de costo de envío y todo análisis de inventario. Conviene iniciarlos en paralelo con la limpieza, ya que su tiempo de respuesta no depende del equipo de datos.
- **Revisar las fechas posteriores a la fecha de corte** (16.485 pedidos, 2,58%). Invalidan el eje temporal de cualquier serie de compras. Decidir entre corregir, si el patrón de error es identificable, o marcar como inválidas y excluir de los análisis temporales.

Prioridad media

- **Deduplicar** las 20.000 filas repetidas. Es una sola instrucción, sin pérdida de información y sin riesgo, y deja la base en los 620.000 registros del enunciado.
- **Imputar **ciudad_tienda** desde **codigo_postal**** para los 29.928 faltantes. Es determinista, no requiere moda ni estimación, y elimina de paso parte del ruido de la segmentación geográfica.
- **Unificar el parseo de fechas** y decidir el tratamiento de las 22.687 no convertibles, separando las 17.061 mal digitadas, que hay que recuperar del origen, de las 5.698 ausentes, que deben marcarse como faltantes.
- **Resolver la incoherencia entre código postal y ciudad** (42.405 registros). Como el código postal está completo al 100% y es verificable contra una fuente oficial, lo razonable es tomarlo como fuente de verdad y reconstruir la ciudad desde él.
- **Tratar los valores numéricos imposibles** (precio y unidades negativos, edad fuera de rango, atípicos extremos). Exigen una regla de negocio explícita, por lo que conviene acordar con el área responsable qué representan los valores repetidos como \$999.000.000, 5.000 y 9.999 antes de descartarlos.
- **Corregir los correos sin arroba** (51.532). El patrón es reconstruible, ya que basta reemplazar por **@** el punto que precede al dominio, aunque conviene recordar que la columna tiene un problema de fondo que la corrección de formato no resuelve.

Prioridad baja

- **Faltantes de **correo_cliente** (16,46%) y de **comentario_cliente** (14,19%).** Son el mayor volumen de nulos del archivo, pero no participan en ningún cálculo y su ausencia es informativa en sí misma, de modo que pueden dejarse vacíos o marcarse explícitamente como desconocidos, sin imputar.
- **Fechas de stock posteriores al corte** (3,39%). Baja proporción y menor criticidad que la fecha de pedido.

7. Limitaciones de la auditoría

Conviene dejar constancia de hasta dónde llega este diagnóstico. Primero, la auditoría detecta y cuantifica, pero no corrige: todas las cifras describen el archivo tal como fue entregado. Segundo, seis de los 37 hallazgos no se pueden cerrar desde los datos, ya que dependen de una confirmación del área que genera el archivo sobre qué representan ciertos valores y por qué ciertas columnas varían como lo hacen. Tercero, el umbral de 180 días para la vigencia del inventario es un supuesto de negocio adoptado por el equipo auditor y no una regla validada con logística, por lo que se dejó explícito y modificable en el código.

Por último, el cruce con la fuente externa depende de que los nombres de municipio del DANE se lleven a la misma forma canónica que los de la base. El notebook incorpora un control que verifica los doce municipios antes de comparar, puesto que una sola ciudad mal alineada introduciría unos 47.000 falsos positivos, más que el total real de discrepancias.