

Informe de Calidad de Datos

NovaMarket · Dataset de ventas

Dataset auditado: NovaMarket_datos_crudos.csv · 640.000 registros × 20 variables

Fecha de corte de la auditoría: 4 de agosto de 2026

Integrantes: María Andrea Torres · Ricardo Borja · Gabriel Murillo Velandia · Laura Marcela Gómez

Documentos que acompañan: S05_PD_Grupo05_PlanSaneamiento.pdf · S05_PD_Grupo05_CatalogoProblemas.xlsx · S05_PD_Grupo05_ConsolidacionHito1.ipynb

1. Resumen ejecutivo

El dataset de ventas de NovaMarket tiene un nivel de **confiabilidad baja** para uso directo. Sobre 640.000 pedidos y 20 variables se identificaron **35 problemas de calidad** distribuidos en las seis dimensiones evaluadas, de los cuales **9 son de severidad alta**.



El hallazgo dominante es la inconsistencia de escritura en las variables categóricas: casi la mitad del archivo tiene la ciudad escrita de forma no normalizada, con 88 variantes para 12 ciudades reales. Es el problema más extendido y, a la vez, el más barato de resolver.

El hallazgo más grave es de otra naturaleza. **Tres variables no se pueden reparar**, puesto que el dato correcto no está en el archivo: la edad varía hasta 40 años dentro de un mismo cliente cuando los pedidos cubren solo tres, el correo identifica la transacción y no a la persona, y la condición de fuga alterna hasta ocho veces en el mismo cliente. Para esas tres no existe imputación posible, solo documentación de la limitación y exclusión del análisis.

En consecuencia, el dataset **hoy sirve** para dimensionar volumen de pedidos y explorar patrones gruesos de venta, y **todavía no sirve** para reportar cifras monetarias, segmentar clientes por perfil demográfico, medir fuga ni alimentar ningún modelo de decisión. El Plan de Saneamiento que acompaña este informe define la ruta para elevar esa confiabilidad.

2. Alcance y metodología

2.1 Qué se auditó

Concepto	Detalle
Archivo	NovaMarket_datos_crudos.csv
Volumen	640.000 registros × 20 variables
Unidad de análisis	El pedido, identificado por <code>id_pedido</code>
Periodo cubierto	Pedidos entre 2023 y 2027, con fecha de corte el 4 de agosto de 2026
Método	Evaluación sobre las seis dimensiones estándar de calidad de datos
Soporte de cálculo	S3_Grupo05_AuditoriaCalidad.ipynb · S04_PD_Borja_EstrategiaFaltantes.ipynb · S05_PD_Grupo05_ConsolidacionHito1.ipynb

2.2 Las seis dimensiones evaluadas

Dimensión	Qué pregunta	Cómo se verificó
Compleitud	¿Falta el dato?	Conteo de nulos por columna, más la detección de faltantes disfrazados de texto
Unicidad	¿El registro está repetido?	Duplicación del identificador y comparación de la fila completa
Validez	¿El valor cumple el formato del campo?	Reglas de formato sobre correo y fecha
Consistencia	¿Se escribe siempre igual y coinciden los campos entre sí?	Normalización de texto y cruce entre ciudad y código de municipio DANE
Exactitud	¿El valor corresponde a la realidad?	Reglas de dominio, coherencia dentro de la misma entidad y contraste contra una referencia
Oportunidad	¿El dato está vigente?	Fechas futuras, desfase entre pedido e inventario y vacíos en la serie temporal

2.3 Las dos bases de conteo

El informe trabaja sobre dos volúmenes distintos y conviene declararlo para que ninguna cifra parezca contradictoria. La **auditoría de dimensiones** se hizo sobre el archivo crudo de 640.000 registros, porque el objetivo era medir el estado del dato tal como llega. El **diagnóstico de valores faltantes** se hizo sobre el archivo ya deduplicado, de **620.000 registros**, porque contar dos veces el mismo pedido distorsionaría cualquier tasa de ausencia. Por eso el correo aparece con 105.312 faltantes en el catálogo y con 102.000 en la tabla de decisiones: son los mismos registros medidos antes y después de eliminar los 20.000 duplicados.

Criterio de clasificación. La frontera entre validez y exactitud se resolvió con una sola pregunta: **¿el valor rompe el formato del campo, o rompe la realidad que el campo describe?** Un correo sin arroba no se puede interpretar y es un problema de validez. Un precio de \$-888.100 se interpreta sin ninguna ambigüedad; lo que falla es que un precio no puede ser negativo, y eso es exactitud. La contradicción entre dos campos del mismo registro es consistencia.

3. Hallazgos por dimensión

Compleitud • ¿Falta el dato?

7 problemas • 321.493 registros afectados • 0 de severidad alta

La dimensión reúne **7 problemas** que afectan a **321.493** registros. El de mayor volumen es **correo_cliente**, con **105.312 registros vacíos (16,46%)**, seguido de **comentario_cliente** con 90.806 (14,19%). Ninguno de los dos entra en cálculos, pero el primero sí tiene consecuencia comercial: el 16,46% de los pedidos no puede recibir comunicación posventa ni entrar en una campaña de correo de Marketing.

Más delicados por su efecto sobre cifras son **precio_unitario** y **monto_compra**, con **21.640 vacíos cada uno (3,38%)** y exactamente en las mismas filas, puesto que el monto se calcula a partir del precio. Imputarlos con la media distorsionaría el ingreso que reporta Finanzas.

El hallazgo más fino de esta dimensión son los **5.698 registros (0,89%)** en los que **fecha_pedido** viene escrita como el texto **00/00/0000**. Es un faltante disfrazado: el conteo tradicional de nulos reporta la columna como completa, lo que da una falsa sensación de calidad.

El tratamiento de estos siete vacíos no se decidió por volumen sino por mecanismo de ausencia, y se detalla en el punto 3.7 y en el Anexo A.

Unicidad • ¿Está repetido?

1 problema • 20.000 registros afectados • 0 de severidad alta

Un solo hallazgo, y es inequívoco: **20.000 pedidos duplicados (3,12%)** en los que el **id_pedido** se repite y la fila es idéntica en las 20 columnas. Cada identificador duplicado aparece exactamente dos veces, de modo que no se trata de un patrón parcial sino de una copia completa del registro. Su efecto sobre el negocio es directo: veinte mil pedidos contados dos veces inflan en 3,12% el ingreso y el número de transacciones que reporta **Finanzas**. Es también el problema más barato de resolver, ya que se corrige eliminando la copia.

Validez • ¿Es un valor posible de leer?

2 problemas • 74.219 registros afectados • 0 de severidad alta

Tras la reclasificación, la dimensión conserva **2 problemas** sobre **74.219** registros, y ambos comparten la misma naturaleza: la cadena no cumple el formato del campo y por eso no se puede interpretar.

El primero son **51.532 correos (8,05%)** con la forma **cliente593809.hotmail.com**, en los que el signo @ fue reemplazado por un punto. Estos correos rebotan al enviarse, de modo que Marketing pierde alcance real en cada campaña sin enterarse.

El segundo son **22.687 fechas (3,54%)** no convertibles a una fecha real, concentradas en cuatro valores: **00/00/0000**, **31/04/2025**, **30/02/2025** y **2026-13-05**. Impiden construir la serie temporal de venta sin descartar esos pedidos.

Consistencia • ¿Se escribe siempre igual y coinciden los campos entre sí?

6 problemas • 1.041.825 registros afectados • 5 de severidad alta

Es la dimensión del hallazgo más extendido del archivo. Reúne **6 problemas** sobre **1.041.825** registros, de los cuales **5 son de severidad alta**.

`ciudad_tienda` presenta **88 variantes de escritura para 12 ciudades reales** y afecta a **314.864 registros (49,20%)**: mayúsculas, tildes, espacios sobrantes, contracciones como *B/quilla* y *Sta. Marta*, nombres largos como *Santiago de Cali*, y códigos de tres letras. El informe de venta por ciudad reparte una misma sede en hasta siete filas distintas, de modo que Operaciones no puede comparar desempeño entre tiendas ni asignar inventario.

El mismo patrón afecta a `categoria_producto` con 304.697 registros (47,61%), `canal_compra` con 154.781 (24,18%), `metodo_pago` con 129.372 (20,21%) y `nivel_satisfaccion` con 95.706 (14,95%).

El sexto hallazgo es de otra clase y es el más específico de la auditoría: en **42.405 registros (6,63%)** el municipio DANE contenido en los cinco primeros dígitos de `codigo_postal` no corresponde a la ciudad declarada en `ciudad_tienda`. La asignación a zona de despacho es incorrecta en esos casos, lo que le cuesta a Logística rutas mal planeadas y entregas fuera de zona.

Exactitud · ¿El valor corresponde a la realidad que describe?

12 problemas · **1.613.170** registros afectados · 3 de severidad alta

Es la dimensión más cargada del archivo, con **12 problemas** sobre **1.613.170** registros, y la única que contiene hallazgos **sin reparación posible**.

La edad varía dentro de un mismo cliente mucho más de lo que permite la ventana temporal del archivo. Los pedidos cubren tres años, de modo que nadie puede envejecer más de tres, y sin embargo el rango mediano de edad dentro de un mismo cliente es de **40 años**: el 97,9% de los clientes con dos o más pedidos supera el tope, lo que compromete a **622.458 registros (97,26%)**. No hay forma de saber cuál de las edades es la verdadera, por lo que ninguna segmentación demográfica es defendible.

`correo_cliente` coincide con `id_pedido` menos 100.000 en el **100%** de los registros y nunca con `id_cliente`, lo que afecta a **534.688 registros (83,55%)**. La columna identifica la transacción y no a la persona, de modo que la base de contacto de NovaMarket no existe como tal.

La condición de fuga alterna de forma repetida dentro del mismo cliente: 45.298 clientes entran y salen de ella dos o más veces, con un máximo de ocho alternancias, sobre **259.564 registros (40,56%)**. El indicador no sirve como variable objetivo de ningún modelo de retención.

Los nueve problemas restantes son valores bien formados pero imposibles: montos menores o iguales a cero (45.182), pesos de hasta 1.399,9 kg sobre una mediana de 11,7 (32.045), unidades negativas (27.877), edades fuera del rango de 0 a 120 años (27.829), precios negativos hasta \$-888.100 (19.629), unidades centinela en 5.000 y 9.999 (18.526), montos por encima de mil millones (16.158) y un tope repetido de \$999.000.000 idéntico en los 24 productos (6.164).

El impacto de este bloque recae sobre **Finanzas**, que no puede reportar un total de ingreso ni un ticket promedio confiables mientras los precios negativos y los topes centinela sigan sumando, y sobre **Logística**, que no puede cotizar flete con pesos de hasta 1.399 kg en un catálogo de bienes de consumo.

Oportunidad · ¿El dato está vigente?

7 problemas · 770.386 registros afectados · 1 de severidad alta

Reúne 7 problemas sobre 770.386 registros, todos concentrados en el eje temporal.

El más grave es también el más pequeño en volumen: 16.485 pedidos (2,58%) están fechados después de la fecha de corte de la auditoría, algunos hasta 2027. Las series de venta incluyen entonces pedidos que no han ocurrido, lo que infla la proyección de cierre de año que Finanzas presenta a la Junta.

El resto describe el desfase entre el pedido y el inventario que lo respalda: 422.000 registros (65,94%) con más de 180 días de separación entre la compra y el último recuento de stock, 102.835 (16,07%) en los que la actualización de stock es anterior al pedido, y 66.069 (10,32%) con el inventario desactualizado más allá del umbral. A esto se suma que no existe ningún registro de stock fechado en 2025, pese a que sí los hay en 2023, 2024 y 2026, lo que rompe cualquier comparación interanual.

3.7 Diagnóstico y tratamiento de los valores faltantes

Los hallazgos de completitud dicen cuánto falta. La pregunta que determina si una imputación es válida o si introduce sesgo es otra: por qué falta. Sobre las siete columnas con vacíos se diagnosticó el mecanismo de ausencia y se decidió una estrategia para cada una.

El único mecanismo que se puede demostrar directamente desde el archivo es MAR, y aparece en una sola columna. nivel_satisfaccion falta en el 20,36% de las compras hechas por la App frente a entre 2,8% y 3,0% en los otros tres canales, con una V de Cramér de 0,291 (p < 0,001) y un AUC de 0,743. El canal explica la ausencia, de modo que la ausencia no es azar.

En las otras seis columnas ninguna variable observada explica el vacío, con AUC entre 0,493 y 0,505. Aquí está la precisión de método que sostiene todo el tratamiento: esa evidencia descarta MAR, pero es compatible a la vez con MCAR y con MNAR. Distinguir entre esos dos es imposible desde el archivo, porque haría falta conocer precisamente el valor que no está. Por eso se rotulan como MCAR aparente, MNAR no descartable y no como MCAR a secas, y por eso la acción tomada en ellas es la conservadora.

La consecuencia práctica es que de siete columnas con vacíos solo una se imputa, y ni siquiera por estimación: ciudad_tienda se recupera por deducción exacta desde los cinco primeros dígitos del código postal, que son el municipio DANE y están presentes en el 100% de los registros. En las otras seis la decisión fue marcar y no inventar. Un tratamiento de faltantes que imputa poco no está incompleto: es un tratamiento que se niega a fabricar información que no existe.

Columna	% faltante	Mecanismo	Estrategia elegida
correo_cliente	16,45%	MCAR aparente, MNAR no descartable	Marcar como «desconocido» y no imputar
comentario_cliente	14,19%	MNAR por diseño	Marcar como «sin comentario» y no imputar
nivel_satisfaccion	7,26%	MAR demostrado	Categoría explícita «Sin dato» más columna indicadora
ciudad_tienda	4,68%	MCAR aparente	Imputación por deducción desde el código postal
precio_unitario	3,39%	MCAR aparente, MNAR no descartable	No imputar. Se deja nulo más columna indicadora
monto_compra	3,39%	Estructural, derivado	No imputar. Se deja nulo más columna indicadora

fecha_pedido	0,89%	MCAR aparente, MNAR no descartable	No imputar. Nulo real más columna indicadora
--------------	-------	------------------------------------	--

La evidencia completa y la justificación de cada decisión están en el Anexo A.

Resumen cuantitativo

Dimensión	Problemas	Registros afectados	Severidad alta
Compleitud	7	321.493	0
Unicidad	1	20.000	0
Validez	2	74.219	0
Consistencia	6	1.041.825	5
Exactitud	12	1.613.170	3
Oportunidad	7	770.386	1
Total	35	3.841.093	9

Un mismo registro puede estar afectado por varios problemas a la vez, por lo que la suma de la columna de registros afectados excede el total de filas auditadas.

4. Catálogo de problemas priorizado

Ordenado de mayor a menor severidad y, dentro de cada nivel, por número de registros afectados. Corresponde a la hoja «Catálogo v2» de S05_PD_Grupo05_CatalogoProblemas.xlsx.

N°	Dimensión	Columna	Descripción	Registros	%	Sev.	Impacto en el negocio
1	Exactitud	edad_cliente, id_cliente	La edad varía dentro de un mismo cliente mucho más de lo que permite la ventana temporal del archivo. Los pedidos cubren 3 años, de modo que nadie puede envejecer más de 3, y sin embargo el rango mediano de edad dentro de un mismo cliente es de 40 años y el 97,9% de los clientes con dos o más pedidos supera el tope. No se puede reparar, puesto que no hay forma de saber cuál de las edades es la verdadera.	622.458	97,26%	Alta	Ninguna segmentación por edad es defendible. Marketing no puede construir audiencias por rango etario ni justificar el presupuesto de campañas dirigidas.
2	Exactitud	correo_cliente	El correo coincide con el id_pedido menos 100.000 en el 100% de los registros y nunca con el id_cliente, por lo que está asociado a la transacción y no a la persona. Un mismo cliente aparece con un correo distinto en cada compra y la columna no sirve como dato de contacto.	534.688	83,55%	Alta	La base de contacto no existe como tal. Marketing no puede ejecutar campañas por correo ni medir apertura, porque cada compra genera una dirección distinta.
3	Consistencia	ciudad_tienda	88 variantes de escritura para 12 ciudades reales: mayúsculas, tildes, espacios sobrantes, contracciones (B/quilla, Sta. Marta), nombres largos (Santiago de Cali, Cartagena de Indias) y códigos de tres letras (BOG, MDE, CTG, BAQ, BGA, MZL, SMR).	314.864	49,20%	Alta	El informe de venta por ciudad reparte una misma sede en hasta siete filas distintas, de modo que Operaciones no puede comparar desempeño entre tiendas ni asignar inventario.
4	Consistencia	categoria_producto	32 variantes de escritura para 6 categorías reales, incluido el par sinónimo Juguetería/juguetes, que la normalización tipográfica no resuelve por sí sola.	304.697	47,61%	Alta	El reporte por categoría subdivide líneas reales, lo que impide a Compras negociar volumen con proveedores sobre cifras consolidadas.

5	Exactitud	fuga_cliente, id_cliente	La condición de fuga alterna de forma repetida dentro del mismo cliente: 45.298 clientes entran y salen de ella dos o más veces, con un máximo de 8 alternancias, sobre una mediana de 4 pedidos por cliente. Un cliente que abandona y regresa tantas veces no describe un estado de abandono.	259.564	40,56%	Alta	El indicador de fuga no sirve como variable objetivo. Cualquier modelo de retención se entrenaría sobre una etiqueta que se contradice a sí misma.
6	Consistencia	canal_compra	20 variantes de escritura para 4 canales (Web, App, Tienda, Marketplace) por diferencias de mayúsculas y espacios sobrantes.	154.781	24,18%	Alta	La medición de rentabilidad por canal queda fragmentada, de modo que no se puede decidir dónde invertir el presupuesto de captación.
7	Consistencia	metodo_pago	20 variantes de escritura para 4 medios de pago (Efectivo, Tarjeta, PayPal, Transferencia), con el mismo patrón de mayúsculas y espacios que canal_compra.	129.372	20,21%	Alta	Finanzas no puede conciliar el recaudo por medio de pago ni estimar el costo real de las comisiones de tarjeta.
8	Consistencia	nivel_satisfaccion	15 variantes de escritura para 3 niveles (Alto, Medio, Bajo). Fragmenta cualquier agregado de satisfacción en varias clases que en realidad son la misma.	95.706	14,95%	Alta	El indicador de satisfacción se reparte en clases que en realidad son la misma, de modo que Servicio al Cliente reporta un nivel que no corresponde a la realidad.
9	Oportunidad	fecha_pedido	16.485 pedidos con fecha posterior a la fecha de corte de la auditoría (04/08/2026), hasta 2027. Invalida el eje temporal de cualquier serie de compras.	16.485	2,58%	Alta	Las series de venta incluyen pedidos fechados en 2027, lo que infla la proyección de cierre de año que Finanzas presenta a la Junta.
10	Oportunidad	fecha_pedido, fecha_actualizacion_stock	Pedido y actualización de stock separados por más de 180 días. Impide medir latencia de inventario, rotación y quiebre de stock.	422.000	65,94%	Media	Impide medir latencia de inventario y rotación, de modo que Logística no puede dimensionar el stock de seguridad.
11	Complejidad	correo_cliente	Registros sin correo electrónico. Es el faltante de mayor volumen del archivo. Cada registro sin correo es un pedido que no puede recibir comunicación posventa ni entrar en una campaña de correo.	105.312	16,46%	Media	El 16,46% de los pedidos no tiene dirección de contacto, lo que reduce en la misma proporción el alcance de cualquier campaña de correo de Marketing.

12	Oportunidad	fecha_actualizacion_stock, fecha_pedido	Fecha de actualización de stock anterior a la fecha del pedido. Por sí solo no es imposible, puesto que el inventario se refresca de forma independiente de las ventas, pero la magnitud no tiene explicación operativa.	102.835	16,07%	Media	El recuento de inventario que respalda el pedido es anterior a la compra, lo que hace inauditable la disponibilidad en el momento de la venta.
13	Oportunidad	fecha_pedido, fecha_actualizacion_stock	Pedidos que se apoyan en un recuento de stock hecho más de 180 días antes de la compra.	75.206	11,75%	Media	Pedidos que se apoyan en un recuento antiguo, lo que aumenta el riesgo de vender sin existencias.
14	Oportunidad	fecha_actualizacion_stock	Stock desactualizado: más de 180 días desde el último recuento, umbral adoptado porque pasado ese plazo el dato ya no describe la disponibilidad actual y la decisión de reposición sería a ciegas.	66.069	10,32%	Media	Un año completo sin registros de stock rompe cualquier comparación interanual de inventario.
15	Oportunidad	fecha_actualizacion_stock	No existe ningún registro fechado en 2025, pese a que sí hay 32.983 en 2023, 33.086 en 2024, 552.209 en 2026 y 21.722 en 2027. Por eso los umbrales de 180, 365 y 540 días devuelven la misma cifra. A confirmar con el área responsable si hubo cambio de sistema o migración.	66.069	10,32%	Media	El dato de inventario deja de ser confiable para reposición pasado ese plazo, con riesgo directo de quiebre de stock.
16	Validez	correo_cliente	Correos sin arroba, con la forma cliente593809@hotmail.com: el signo @ fue reemplazado por un punto. El perfilado por firma de patrón lo confirma de forma independiente.	51.532	8,05%	Media	Los correos con punto en lugar de arroba rebotan al enviarse, de modo que Marketing pierde alcance real en cada campaña.
17	Complejidad	nivel_satisfaccion	Registros sin nivel de satisfacción. Se pierde la observación en todo cruce de satisfacción y la ausencia puede no ser aleatoria.	46.469	7,26%	Media	Se pierde la observación en todo cruce de satisfacción, y la ausencia se concentra en el canal App, lo que sesgaría la lectura si se ignora.
18	Exactitud	monto_compra	Monto de compra menor o igual a cero. Es el arrastre aritmético exacto de los precios y las unidades negativas, no un error propio de la columna: corregir el origen corrige el derivado.	45.182	7,06%	Media	45.182 pedidos restan en lugar de sumar al ingreso, de modo que el total de ventas que reporta Finanzas queda subestimado.

19	Consistencia	ciudad_tienda, codigo_postal	El municipio DANE contenido en los 5 primeros dígitos del código postal no corresponde a la ciudad declarada. Verificado contra la codificación DIVIPOLA oficial. Se reparte en 132 combinaciones distintas, con 321 registros de promedio cada una.	42.405	6,63%	Media	La asignación de pedidos a zona de despacho es incorrecta en 42.405 casos, lo que le cuesta a Logística rutas mal planeadas y entregas fuera de zona.
20	Exactitud	peso_pedido_kg	Peso superior a 100 kg, hasta 1.399,9 kg, sobre una mediana de 11,7 kg, en un catálogo de bienes de consumo de tamaño medio.	32.045	5,01%	Media	Los pesos de hasta 1.399 kg distorsionan el costo de flete estimado y hacen inservible cualquier cotización de transporte.
21	Compleitud	ciudad_tienda	Registros sin ciudad de tienda. Rompe la segmentación geográfica, aunque son imputables de forma determinista desde codigo_postal, que está completo al 100%.	29.928	4,68%	Media	Rompe la segmentación geográfica, aunque es recuperable de forma exacta desde el código postal del mismo registro.
22	Exactitud	unidades_vendidas	Unidades vendidas menores o iguales a cero: 18.550 negativas, hasta -3 unidades por pedido, y 9.327 pedidos registrados con cero unidades.	27.877	4,36%	Media	Las unidades negativas se mezclan con devoluciones legítimas, de modo que no se puede medir rotación de producto.
23	Exactitud	edad_cliente	Edad fuera del rango 0 a 120 años: valores negativos hasta -5 y hasta 200 años.	27.829	4,35%	Media	Los perfiles con edad negativa o de 200 años contaminan cualquier segmentación demográfica de Marketing.
24	Validez	fecha_pedido	Fechas no convertibles a una fecha real. Son cuatro valores: 30/02/2025 (5.675), 31/04/2025 (5.688), 2026-13-05 (5.626) y 00/00/0000 (5.698). Los tres primeros son errores de digitación; el cuarto es un dato ausente y se cuenta también en completitud.	22.687	3,54%	Media	Cuatro fechas imposibles impiden construir la serie temporal de venta sin descartar esos pedidos.
25	Compleitud	precio_unitario	Registros sin precio unitario. Entra en cálculos monetarios, por lo que imputarlo con la media distorsiona los agregados de venta.	21.640	3,38%	Media	Entra en cálculos monetarios, de modo que imputarlo con la media distorsionaría el ingreso reportado.

26	Compleitud	monto_compra	Registros sin monto de compra. Son exactamente las mismas filas que las de precio_unitario, porque el monto se deriva de él.	21.640	3,38%	Media	Son exactamente las mismas filas que precio_unitario, de modo que el ingreso de esos pedidos no se puede reconstruir.
27	Unicidad	todas las columnas	20.000 pedidos duplicados: el id_pedido se repite y además la fila es idéntica en las 20 columnas y cada identificador afectado aparece exactamente dos veces. Es una carga duplicada del archivo y no una colisión real de clave.	20.000	3,12%	Media	Veinte mil pedidos contados dos veces inflan el ingreso y el número de transacciones en 3,12%.
28	Exactitud	precio_unitario	Precio unitario negativo, hasta -\$888.100. Afecta directamente el cálculo de ingresos y arrastra el error a monto_compra.	19.629	3,07%	Media	El precio negativo arrastra el error a monto_compra y al margen por producto que revisa Finanzas.
29	Exactitud	unidades_vendidas	Unidades atípicas fuera de toda escala minorista, concentradas en solo dos valores: 5.000 y 9.999. Apunta a marcadores del sistema de origen antes que a errores de digitación.	18.526	2,89%	Media	Dos valores centinela inflan el volumen vendido y distorsionan la proyección de reposición de inventario.
30	Exactitud	monto_compra	Monto de compra por encima de 1.000 millones de pesos en valor absoluto.	16.158	2,52%	Media	Dieciséis mil tickets por encima de mil millones desplazan cualquier promedio de ticket que se use para fijar metas comerciales.
31	Exactitud	precio_unitario	Precio unitario superior a \$10.000.000, con un máximo de \$999.000.000 idéntico en los 24 productos. Un tope repetido de esa forma apunta a un marcador del sistema de origen.	6.164	0,96%	Media	El tope repetido de 999 millones es un valor centinela, no un precio, y contamina el ingreso por artículo.
32	Compleitud	fecha_pedido	Registros sin fecha de pedido, escritos como el texto 00/00/0000. Con el conteo tradicional de nulos la columna figura como completa al 100% porque las celdas tienen contenido; solo aparecen al leer el archivo en texto crudo.	5.698	0,89%	Media	Faltante disfrazado de texto. El conteo tradicional de nulos lo reporta como completo, lo que da una falsa sensación de calidad del dato.
33	Exactitud	precio_unitario	Precio unitario superior a 100 millones de pesos.	3.050	0,48%	Media	Subconjunto del anterior, con el mismo efecto sobre el ingreso por artículo.

34	Compleitud	comentario_cliente	Registros sin comentario. Es un texto libre opcional y su ausencia es informativa en sí misma, por lo que no debería imputarse.	90.806	14,19%	Baja	Texto libre opcional. Su ausencia reduce la muestra para análisis de voz del cliente, sin afectar ninguna cifra.
35	Oportunidad	fecha_actualizacion_stock	Fecha de actualización de stock posterior a la fecha de corte de la auditoría.	21.722	3,39%	Baja	Fechas de inventario posteriores al corte que impiden cerrar el periodo con cifras estables.

5. Conclusión de confiabilidad

Veredicto: confiabilidad **BAJA**

El dataset de ventas de NovaMarket no admite análisis directo. De los 35 problemas identificados, 9 son de severidad alta, el más extendido compromete al 49,20% del archivo y tres variables no tienen reparación posible porque el dato correcto no está en el archivo.

Para qué sirve hoy

- Dimensionar el **volumen de pedidos** por periodo, una vez eliminados los 20.000 duplicados y los 16.485 pedidos con fecha posterior al corte.
- Explorar **patrones gruesos de venta** por categoría y canal, siempre que se normalice previamente la escritura de esas variables.
- Servir de base para el **saneamiento** descrito en el documento que acompaña este informe, puesto que la mayoría de los defectos son sistemáticos y no aleatorios, lo que los hace tratables.

Para qué todavía no sirve

- **Reportar cifras monetarias.** Los precios negativos, el tope centinela de \$999.000.000 y los montos por encima de mil millones contaminan cualquier total de ingreso.
- **Segmentar clientes por perfil demográfico.** La edad es incoherente en el 97,26% de los registros y no se puede reconstruir.
- **Medir o predecir la fuga de clientes.** La etiqueta se contradice a sí misma dentro del mismo cliente.
- **Ejecutar campañas de contacto.** El correo identifica la transacción y no a la persona.
- **Alimentar cualquier modelo de decisión,** por la suma de las razones anteriores.

Ruta hacia una confiabilidad media

De los 35 problemas, **31 son tratables** con las técnicas previstas para las semanas 6 a 10, y la mayoría se resuelve con normalización de texto y reglas de dominio. Los cuatro restantes no se resuelven en ninguna semana: las **tres variables sin reparación posible**, que son edad, correo y fuga, y la **ausencia completa de registros de stock en 2025**, que es un vacío de la serie y no un defecto de filas individuales. Los cuatro se documentan como limitación conocida. Ejecutado ese plan, el dataset alcanzaría confiabilidad media: utilizable para análisis descriptivo y para reportes de gestión, aunque todavía no para modelos que dependan de las tres variables excluidas.

Anexo A · Tabla de decisiones sobre valores faltantes

Diagnóstico de mecanismo y estrategia adoptada para cada una de las siete columnas con vacíos. Las cifras corresponden al archivo deduplicado de 620.000 registros. Corresponde a la hoja «Estrategia de faltantes» de S05_PD_Grupo05_CatalogoProblemas.xlsx.

Columna	% falt.	Mecanismo	Evidencia	Estrategia elegida	Justificación
correo_cliente	16,45%	MCAR aparente, MNAR no descartable	AUC 0,502; sin asociación con ninguna variable observada	Marcar como «desconocido» y no imputar	Inventar una dirección de correo no aporta información y crearía la ilusión de una base de contacto que no existe.
comentario_cliente	14,19%	MNAR por diseño	AUC 0,505; el comentario es opcional por definición del formulario	Marcar como «sin comentario» y no imputar	La ausencia es informativa en sí misma: no comentar es una respuesta, no un dato perdido.
nivel_satisfaccion	7,26%	MAR demostrado	canal_compra V de Cramér = 0,291 con $p < 0,001$; AUC 0,743; App 20,36% frente a 2,8% a 3,0% en los otros tres canales	Categoría explícita «Sin dato» más columna indicadora	Imputar un nivel fabricaría una opinión que el cliente nunca dio. Como la satisfacción se distribuye igual en los cuatro canales, imputar condicionando en el canal daría casi lo mismo que la moda global y ocultaría que en App falta uno de cada cinco.
ciudad_tienda	4,68%	MCAR aparente	AUC 0,503; ningún contraste supera $V = 0,01$	Imputación por deducción desde el código postal	No es una estimación sino una recuperación exacta: los cinco primeros dígitos del código postal son el municipio DANE y la columna está completa al 100%. Cubre los 29.000 faltantes sin excepción.
precio_unitario	3,39%	MCAR aparente, MNAR no descartable	AUC 0,493; sin asociación con ninguna variable observada	No imputar. Se deja nulo más columna indicadora	La auditoría midió eta cuadrado = 0,000026 entre precio y producto: el artículo no explica el precio, de modo que no existe una referencia de la cual partir. Imputar con la mediana global asignaría el mismo precio a una bicicleta estática y a una bufanda.
monto_compra	3,39%	Estructural, derivado	Intersección exacta de 21.000 con precio_unitario, sin una sola excepción	No imputar. Se deja nulo más columna indicadora	monto = precio × unidades se cumple en el 100% de los registros evaluables, de modo que el vacío del monto es consecuencia del vacío del precio y se trata igual que su causa.
fecha_pedido	0,89%	MCAR aparente, MNAR no descartable	AUC 0,496; sin asociación con ninguna variable observada	No imputar. Nulo real más columna indicadora	Proviene del centinela 00/00/0000. Inventar una fecha desplazaría pedidos en la serie temporal, que es justo lo que la columna debe sostener.

Criterio general aplicado. MCAR con menos del 5% de faltantes admite eliminación de filas; MAR exige imputación condicionada en la variable que explica la ausencia; MNAR o sospechado se trata con columna indicadora, sin imputar el valor. Cuando ninguna variable observada explica la ausencia, la evidencia descarta MAR pero es compatible a la vez con MCAR y con MNAR, por lo que la acción tomada es la conservadora.

Anexo B · Verificaciones que no arrojaron un veredicto concluyente

Tres verificaciones no permitieron concluir si el dato es correcto o incorrecto, puesto que no existe una referencia contra la cual contrastarlo. No son problemas de calidad y por eso no forman parte del catálogo. Se documentan aquí porque delimitan el alcance de lo que la auditoría pudo comprobar.

Columna	Alcance	%	Por qué no concluye
precio_unitario, producto	592.567	92,59%	El producto explica una fracción despreciable de la varianza del precio (eta cuadrado = 0,000026) y ninguno de los 120 grupos de producto y cantidad tiene un precio único. No hay referencia contra la cual comparar.
peso_pedido_kg	607.955	94,99%	Eta cuadrado de 0,000046 frente al producto y correlación de -0,0009 frente a las unidades vendidas. Una bicicleta estática pesa en promedio lo mismo que una bufanda.
fecha_actualizacion_stock	639.005	99,84%	Solo 995 registros tienen una fecha de stock contrastable, sobre 7.406 grupos de sede y producto. El hallazgo es de comportamiento de la columna, no un conteo de registros erróneos.

María Andrea Torres
Analista de Datos

Ricardo Borja
Analista de Datos

Gabriel Murillo Velandia
Analista de Datos

Laura Marcela Gómez
Analista de Datos