

PREPROCESAMIENTO DE DATOS · GRUPO 05 · HITO 1

Plan de Saneamiento

NovaMarket · Hoja de ruta hacia la Misión 2

Documento base: S05_PD_Grupo05_InformeCalidadDatos.pdf

Catálogo de origen: S05_PD_Grupo05_CatalogoProblemas.xlsx · 35 problemas

Integrantes: María Andrea Torres · Ricardo Borja · Gabriel Murillo Velandia · Laura Marcela Gómez

Fecha: 18 de agosto de 2026

1. Propósito y alcance

El Informe de Calidad de Datos responde qué tan confiable es el dataset de ventas de NovaMarket. Este documento responde la pregunta siguiente: **qué se va a hacer con cada problema, en qué orden y en qué momento.**

El plan cubre **los 35 problemas del catálogo, sin excepción.** Ninguno queda sin estrategia asignada, incluidos los cuatro que no se resuelven en ninguna semana de la Misión 2: las tres variables sin reparación posible, que son edad, correo y fuga, y la ausencia completa de registros de stock en 2025. Para esos cuatro la estrategia es la exclusión documentada y no el silencio.

35	18	9	4	4
problemas con estrategia asignada	se resuelven en la Semana 6	se resuelven en la Semana 7	se resuelven en la Semana 10	no se resuelven: se documentan

2. Criterio de priorización

La prioridad combina dos factores, tal como exige el método: **la gravedad del problema**, medida por su severidad y por el porcentaje de registros afectados, y **la urgencia para el negocio**, medida por el área que queda bloqueada mientras el problema persista.

Prioridad	Cantidad	Regla que la asigna
Alta	10	Severidad alta en el catálogo, o problema que bloquea la ejecución de los demás pasos. Los 20.000 duplicados entran aquí pese a su severidad media, puesto que trabajar sobre un archivo duplicado distorsiona toda estadística posterior.
Media	12	Severidad media con más del 5% de los registros afectados.
Baja	13	Severidad media o baja con menos del 5% de los registros afectados.

Dentro de un mismo nivel de prioridad, el criterio de desempate es el número de registros afectados: primero el que compromete a más filas.

Sobre las Semanas 8 y 9. Ningún problema del catálogo se resuelve en escalado (Semana 8) ni en codificación (Semana 9), y conviene decirlo de forma explícita en lugar de repartir filas para que ninguna semana quede vacía. El escalado y la codificación no corrigen defectos: preparan para el modelado variables que ya deben estar saneadas. Por eso aparecen en la columna de estrategia de varias filas como paso posterior, no como el momento en que el problema se resuelve.

3. Plan de saneamiento

Ordenado por prioridad y, dentro de cada nivel, por semana de ejecución y volumen de registros afectados.

Problema	Estrategia propuesta	Prioridad	Semana de la Misión 2
Escritura de ciudad_tienda: 88 variantes para 12 ciudades reales	Estandarización de texto: paso a minúsculas, eliminación de tildes y espacios sobrantes, y diccionario de equivalencias para contracciones (B/quilla, Sta. Marta), nombres largos (Santiago de Cali) y códigos de tres letras (BOG, MDE). Su codificación para modelado se hace en la Semana 9.	Alta	Semana 6
Escritura de categoria_producto: 32 variantes para 6 categorías	Estandarización tipográfica más resolución manual del par sinónimo Juguetería y juguetes, que la normalización automática no unifica. Se codifica en la Semana 9.	Alta	Semana 6
Escritura de canal_compra: 20 variantes para 4 canales	Estandarización tipográfica y mapeo contra el catálogo cerrado de cuatro canales. Codificación one-hot en la Semana 9.	Alta	Semana 6
Escritura de metodo_pago: 20 variantes para 4 medios de pago	Estandarización tipográfica y mapeo contra el catálogo cerrado de cuatro medios. Codificación one-hot en la Semana 9.	Alta	Semana 6
Escritura de nivel_satisfaccion: 15 variantes para 3 niveles	Estandarización tipográfica y mapeo a los tres niveles reales. Al ser una variable ordinal, su codificación en la Semana 9 debe preservar el orden Bajo, Medio, Alto.	Alta	Semana 6
20.000 pedidos duplicados, idénticos en las 20 columnas	Eliminación de la copia conservando la primera aparición. Se ejecuta antes que cualquier otro paso , puesto que trabajar sobre un archivo con duplicados distorsiona toda estadística posterior.	Alta	Semana 6
16.485 pedidos fechados después de la fecha de corte	Filtrado de los registros con fecha_pedido posterior al 4 de agosto de 2026 y reporte del volumen excluido, para que ningún análisis temporal los incluya sin saberlo.	Alta	Semana 6
Edad incoherente dentro de un mismo cliente	Sin reparación posible. No hay forma de determinar cuál de las edades registradas es la verdadera, puesto que el dato correcto no está en el archivo. Se excluye edad_cliente del conjunto de análisis y se documenta como limitación conocida en la ficha del dataset.	Alta	No aplica
El correo identifica la transacción y no a la persona	Sin reparación posible. Se excluye correo_cliente como dato de contacto y se deja constancia de que NovaMarket no dispone hoy de una base de correo por cliente. Reconstruirla exige una fuente externa al archivo.	Alta	No aplica
La condición de fuga alterna dentro del mismo cliente	Sin reparación posible. Se excluye fuga_cliente como variable objetivo y se documenta que cualquier modelo de retención requiere una definición de fuga construida desde cero sobre la fecha del último pedido.	Alta	No aplica
105.312 registros sin correo electrónico	No se imputa. Se marca explícitamente como «Sin dato» y se reporta el 16,46% como límite de alcance de cualquier campaña de correo.	Media	Semana 6
90.806 registros sin comentario del cliente	No se imputa. La ausencia de comentario es informativa en sí misma y se codifica como una categoría propia.	Media	Semana 6

51.532 correos con punto en lugar de arroba	Corrección del formato mediante expresión regular que restituye el signo @ cuando el patrón es inequívoco. Los que no se puedan corregir se marcan como inválidos.	Media	Semana 6
46.469 registros sin nivel de satisfacción	Imputación por categoría «Sin dato» en lugar de por moda, puesto que la ausencia podría estar concentrada en un canal e imputarla sesgaría el indicador. La decisión está sustentada en el análisis de la Semana 4.	Media	Semana 6
Ciudad y municipio DANE del código postal se contradicen	Se adopta el código postal como fuente de verdad, puesto que es un dato estructurado, y se corrige <code>ciudad_tienda</code> a partir del municipio DANE. Los registros corregidos quedan marcados con una bandera de trazabilidad.	Media	Semana 6
45.182 montos de compra menores o iguales a cero	Arrastre aritmético de los precios y las unidades negativas. Se recalcula el monto una vez corregidas ambas variables de origen, en lugar de tratarlo por separado.	Media	Semana 7
32.045 pesos superiores a 100 kg, hasta 1.399,9 kg	Recorte por regla de dominio del catálogo de bienes de consumo, no por percentil. Los valores por encima del tope se marcan como nulos.	Media	Semana 7
422.000 pedidos separados del recuento de stock por más de 180 días	No se corrige el dato: se deriva la variable <code>latencia_stock_dias</code> y se marca cada pedido según si su inventario de respaldo es utilizable o no.	Media	Semana 10
102.835 registros con la actualización de stock anterior al pedido	Se deriva una bandera de anterioridad y se documenta que la disponibilidad en el momento de la venta no es auditable en esos casos.	Media	Semana 10
75.206 pedidos apoyados en un recuento de más de 180 días antes	Queda cubierto por la misma variable derivada de latencia, con el umbral de 180 días como punto de corte declarado.	Media	Semana 10
66.069 registros con el stock desactualizado más de 180 días	Se marca con la bandera de vigencia derivada de la latencia, de modo que ningún cálculo de reposición los use sin advertencia.	Media	Semana 10
Ningún registro de stock fechado en 2025	No es un defecto de registros individuales sino un vacío en la serie. No se imputa: se documenta como discontinuidad conocida y se prohíbe la comparación interanual que cruce ese año.	Media	No aplica
29.928 registros sin ciudad de tienda	Imputación determinista a partir del municipio DANE del código postal, que está presente en esos registros. No requiere estimación.	Baja	Semana 6
22.687 fechas no convertibles a una fecha real	Conversión con los dos formatos presentes en la columna y marcado como faltante de los cuatro valores imposibles: 00/00/0000, 31/04/2025, 30/02/2025 y 2026-13-05.	Baja	Semana 6
21.722 registros de stock con fecha posterior al corte	Mismo tratamiento que el anterior aplicado a <code>fecha_actualizacion_stock</code> : la fecha se marca como no válida en lugar de eliminar el pedido completo.	Baja	Semana 6
21.640 registros sin precio unitario	No se imputa con la media, puesto que distorsionaría el ingreso. Se conserva como faltante y esos pedidos se excluyen de todo cálculo monetario, con el volumen reportado.	Baja	Semana 6

21.640 registros sin monto de compra	Son las mismas filas que las de precio unitario. Donde exista precio y unidades, el monto se reconstruye por producto; en el resto se conserva como faltante.	Baja	Semana 6
5.698 fechas escritas como el texto 00/00/0000	Conversión explícita del centinela a valor nulo, de modo que el conteo de faltantes deje de subestimar la incompletitud real de la columna.	Baja	Semana 6
27.877 unidades vendidas menores o iguales a cero	Se separan las 18.550 negativas, que se marcan como nulas, de los 9.327 ceros, que pueden corresponder a pedidos anulados y se conservan con una bandera.	Baja	Semana 7
27.829 edades fuera del rango de 0 a 120 años	Se marcan como nulas. No se imputan, puesto que la variable ya está comprometida por el hallazgo de incoherencia dentro del cliente y quedará excluida del análisis.	Baja	Semana 7
19.629 precios unitarios negativos, hasta -\$888.100	Tratamiento como valor imposible, no como atípico legítimo: se marca como nulo y se recalcula <code>monto_compra</code> donde sea posible. Escalado de la variable ya limpia en la Semana 8.	Baja	Semana 7
18.526 unidades atípicas concentradas en 5.000 y 9.999	Dos valores centinela, no una cola larga de la distribución. Se convierten a nulo en lugar de recortarlos por percentil, que es el error habitual.	Baja	Semana 7
16.158 montos por encima de 1.000 millones	Mismo origen aritmético. Se recalcula tras la corrección de precio y unidades, y lo que persista se marca como nulo.	Baja	Semana 7
6.164 precios con el tope centinela de \$999.000.000	El valor es idéntico en los 24 productos, lo que confirma que es un centinela y no un precio. Se convierte a nulo.	Baja	Semana 7
3.050 precios por encima de 100 millones	Subconjunto del anterior. Se resuelve con la misma regla de tope, sin tratamiento adicional.	Baja	Semana 7

4. La ruta, semana por semana

Semana 6 · Limpieza de inconsistencias · 18 problemas

Es la semana que más carga concentra y la que produce el salto de calidad más visible. Arranca eliminando los 20.000 duplicados, puesto que todo lo demás se calcula sobre el archivo resultante. Sigue con la normalización de las cinco variables categóricas, que por sí sola resuelve el problema más extendido del archivo: las 88 variantes de ciudad quedan reducidas a 12, las 32 de categoría a 6, y las de canal, medio de pago y satisfacción a sus catálogos cerrados. Cierra con el tratamiento de faltantes ya definido en la Semana 4 y con el filtrado de los pedidos fechados después del corte.

Semana 7 · Valores atípicos e imposibles · 9 problemas

Aquí se tratan los nueve hallazgos de exactitud cuyos valores están bien formados pero describen algo que no pudo ocurrir. La distinción operativa que gobierna esta semana es que **no todos los valores extremos son atípicos**: el tope de \$999.000.000 repetido idéntico en los 24 productos y las unidades concentradas en 5.000 y 9.999 son centinelas, no colas de una distribución, y por eso se convierten a nulo en lugar de recortarse por percentil. Recortar por percentil aquí sería el error de método más caro del plan.

Semana 8 · Escalado · sin problemas asignados

No resuelve ningún hallazgo del catálogo. Aplica a `precio_unitario`, `monto_compra`, `peso_pedido_kg` y `unidades_vendidas` una vez saneadas en las semanas anteriores, como preparación para el modelado.

Semana 9 · Codificación · sin problemas asignados

Tampoco resuelve hallazgos. Codifica las cinco variables categóricas ya normalizadas en la Semana 6, con la precisión de que `nivel_satisfaccion` es ordinal y su codificación debe preservar el orden Bajo, Medio, Alto en lugar de tratarse como nominal.

Semana 10 · Transformaciones · 4 problemas

Los cuatro problemas de oportunidad relacionados con el desfase entre el pedido y su inventario de respaldo no se corrigen, se **modelan**: se deriva la variable `latencia_stock_dias` y un conjunto de banderas de vigencia que permiten a Logística distinguir los pedidos cuyo inventario de respaldo es utilizable de los que no. Es la diferencia entre borrar un problema y hacerlo explícito y medible.

Fuera de la ruta · 4 problemas sin reparación posible

La edad, el correo y la condición de fuga no se reparan porque el dato correcto no existe en el archivo, y a ellos se suma la ausencia completa de registros de stock en 2025, que es un vacío de la serie y no un defecto de filas individuales. Para los cuatro la estrategia es la misma: exclusión de la variable del conjunto de análisis y documentación explícita de la limitación en la ficha del dataset. Imputarlos sería inventar información.

5. Estado esperado del dataset al final de la Misión 2

Al aplicar este plan completo, el dataset de ventas de NovaMarket quedará **sin registros duplicados**, con las cinco variables categóricas reducidas a sus valores reales (12 ciudades, 6 categorías, 4 canales, 4 medios de pago y 3 niveles de satisfacción) y **sin ningún pedido fechado después del 4 de agosto de 2026**. Las variables monetarias y de peso quedarán dentro de rangos verificables, sin precios negativos ni el tope centinela de \$999.000.000, y con los faltantes de precio y monto conservados como tales en lugar de imputados, de modo que ninguna cifra de ingreso quede inventada. Las cuatro situaciones sin reparación posible, que corresponden a **edad, correo, fuga de cliente y la discontinuidad de 2025**, quedarán excluidas del conjunto de análisis y documentadas como limitación conocida en la ficha del dataset. Con ello el dataset pasa de **confiabilidad baja a media**: utilizable para reportes de gestión y análisis descriptivo por ciudad, categoría, canal y periodo, aunque todavía no para modelos que dependan del perfil demográfico del cliente o de su condición de fuga.

Cómo se verifica que el plan se cumplió

Comprobación	Resultado esperado	Semana
Conteo de <code>id_pedido</code> duplicados	0	6
Valores distintos en <code>ciudad_tienda</code>	12	6
Valores distintos en <code>categoria_producto</code>	6	6
Valores distintos en <code>canal_compra</code> y <code>metodo_pago</code>	4 en cada una	6
Valores distintos en <code>nivel_satisfaccion</code>	3, más la categoría «Sin dato»	6
Pedidos con fecha posterior al corte	0	6
Registros con ciudad y municipio DANE contradictorios	0	6
Precios unitarios negativos o iguales al tope centinela	0	7
Pesos por encima de 100 kg	0	7
Existencia de <code>latencia_stock_dias</code> y sus banderas	Presentes en las 620.000 filas resultantes	10
Variables excluidas y documentadas en la ficha del dataset	4	Cierre

Gabriel Murillo Velandia
Analista de Datos

Laura Marcela Gómez
Analista de Datos